

Avanços em Inteligência Artificial

EELT7025 — PPGEE, UFPR

Exercícios da Aula 05

Otimização de hiperparâmetros na resistência à compressão do concreto

Adriely Teixeira de Paula

Betina Zynger Capaverde

Emilio Gaudeda Junior

30 de setembro de 2026

Sumário

1	Protocolo, objetivo e rastreabilidade	2
2	Exercício 1 — preparação, baseline e buscas clássicas	2
2.1	1. Carregamento, qualidade e pré-processamento	2
2.2	2. Modelo baseline sem otimização	5
2.3	3. Busca em grade e espaço de hiperparâmetros	6
2.4	4. Busca aleatória, convergência e sensibilidade	7
2.5	5. Síntese do exercício 1	8
3	Exercício 2 — otimização Bayesiana, metaheurísticas e avaliação	9
3.1	6. Processo Gaussiano e Expected Improvement	9
3.2	7. Cinco bibliotecas de otimização Bayesiana	10
3.3	8. Metaheurísticas: GA, DE e PSO	12
3.4	9. Dashboard comparativo e diagnósticos finais	14
3.5	10. Importância, robustez, custo-benefício e recomendação	17
A	Parâmetros selecionados e contabilidade computacional	21
B	Ambiente e evidências de reprodução	22
C	Dez iterações do GP manual	24

1 Protocolo, objetivo e rastreabilidade

Comparamos estratégias de otimização de hiperparâmetros (HPO) de um único `GradientBoostingRegressor` sobre o dataset *Concrete Compressive Strength*, UCI 165, com resistência à compressão em MPa[1]. Os dois exercícios usam o mesmo conjunto de dados, a mesma divisão treino/teste e os mesmos cinco folds. O objetivo é medir qualidade preditiva e custo; não foi fornecido um limiar industrial de erro aceitável.

O protocolo local e o orçamento foram fixados antes dos resultados em `study-protocol.md` e `search-budget.json`, seguindo práticas de investigação do *rnd-superpowers*, no commit solicitado[2]. A referência da disciplina orienta os itens 1–10[3]. As lições das tarefas anteriores foram incorporadas como verificação do inventário completo, registro das exclusões e confronto entre conclusões e resultados. Não havia comentário docente disponível nas fontes nem no painel de revisão consultado; essa revisão não é atribuída ao professor.

Desenho da comparação. É um estudo computacional exploratório em um dataset e um holdout. A configuração de cada método é escolhida pelo RMSE médio de validação cruzada, isto é, a média dos cinco RMSEs de folds, não o RMSE de previsões out-of-fold agrupadas; o teste apenas avalia essa configuração. A seleção posterior do menor RMSE de teste, exigida nos itens 9.4 e 10.2, é descritiva e informada pelos resultados. A seleção pelo menor CV é apresentada separadamente da recomendação operacional, que pondera qualidade e custo após os resultados. Não se afirma superioridade estatística universal nem validação confirmatória independente depois dessa seleção.

Tempo e recursos. Cada tempo total soma busca/CV e um ajuste final; instalação, download, gráficos, previsão de teste e serialização final ficam fora. Para o baseline, o total inclui CV e fit, e o fit é informado separadamente. Usaram-se 5 folds concorrentes, estimadores com limite de uma thread e métodos executados sequencialmente em CPU local. O pool loky de processos foi aquecido fora do cronômetro; Ray usa cinco threads de folds dentro de um trial. Os tempos incluem overhead dos otimizadores e refletem esta execução, sujeitos à carga da máquina.

2 Exercício 1 — preparação, baseline e buscas clássicas

2.1 1. Carregamento, qualidade e pré-processamento

Os dados foram obtidos por `ucimlrepo.fetch_ucirepo(id=165)`. O arquivo bruto contém 1030 linhas e 9 colunas (oito preditores e um alvo). Foram removidas 25 duplicatas exatas da linha completa, conservando a primeira ocorrência; restaram 1005 observações. Zero é um valor válido dos ingredientes, não um código de ausência. Nenhuma observação foi removida com base no erro do modelo.

Tabela 1: Qualidade de todas as colunas no arquivo bruto.

Variável	Tipo lido	Ausentes	Proporção
Cimento	float64	0	0,00%
Escória	float64	0	0,00%
Cinza volante	float64	0	0,00%
Água	float64	0	0,00%
Superplastificante	float64	0	0,00%
Agregado graúdo	float64	0	0,00%
Agregado miúdo	float64	0	0,00%
Idade	int64	0	0,00%
Resistência	float64	0	0,00%

Tabela 2: Estatísticas descritivas brutas ($n = 1030$ em todas as variáveis). Ingredientes em kg/m^3 , idade em dias e alvo em MPa.

Variável	Média	DP	Mín.	Q_1	Mediana	Q_3	Máx.
Cimento	281,17	104,51	102,00	192,38	272,90	350,00	540,00
Escória	73,90	86,28	0,00	0,00	22,00	142,95	359,40
Cinza volante	54,19	64,00	0,00	0,00	0,00	118,30	200,10
Água	181,57	21,35	121,80	164,90	185,00	192,00	247,00
Superplastificante	6,20	5,97	0,00	0,00	6,40	10,20	32,20
Agregado graúdo	972,92	77,75	801,00	932,00	968,00	1029,40	1145,00
Agregado miúdo	773,58	80,18	594,00	730,95	779,50	824,00	992,60
Idade	45,66	63,17	1,00	7,00	28,00	56,00	365,00
Resistência	35,82	16,71	2,33	23,71	34,45	46,14	82,60

A limpeza precedeu a divisão aleatória 80/20 com `random_state=42`: 804 observações de treino e 201 de teste. A validação usa `KFold(5, shuffle=True, random_state=42)` com índices congelados. Imputação por mediana, `StandardScaler` e GBR são um único pipeline ajustado dentro de cada fold e, no refit, somente no treino. A imputação é uma regra preventiva; sua necessidade efetiva está na tabela de ausentes. A padronização é exigida pelo enunciado, embora as árvores não dependam dela. O alvo não é padronizado, preservando MPa nas métricas.

O `describe()` global exigido pelo roteiro expõe estatísticas agregadas de todo o arquivo; a EDA gráfica substantiva abaixo usa apenas o treino. A unidade é uma observação de composição e idade do concreto. A divisão por linha não comprova independência entre misturas relacionadas; faltam identificadores de lote para avaliar generalização entre laboratórios ou lotes desconhecidos.

Sobreposição de composições. Depois de remover duplicatas completas de preditores e alvo, a auditoria encontrou 5 vetores de preditores idênticos presentes em treino e teste, envolvendo 8 linhas de treino e 5 de teste, com respostas distintas nas linhas não duplicadas. Podem ser medições relacionadas da mesma composição e idade. Assim, o holdout por linha avalia observações retidas; ele não valida previsão para receitas inéditas. Uma avaliação por grupos de composição é uma extensão necessária para essa outra pergunta, não executada nem substituída pelo split exigido aqui.

No treino, a resistência tem mediana 33,74 MPa, intervalo observado [3,32; 79,99] MPa e assimetria 0,391. A associação linear marginal de maior módulo com o alvo foi de Cimento, $r = 0,497$. O scatter e o mapa de calor complementam esse resumo: relações não lineares ou interações podem ser úteis ao GBR mesmo quando a correlação marginal é menor.




Figura 1: Distribuição do alvo e relação entre cimento e resistência no conjunto de treino.




Figura 2: Correlações no treino; associações descritivas não identificam efeitos causais.

2.2 2. Modelo baseline sem otimização

A referência usa os parâmetros padrão do scikit-learn[4], exceto `random_state=42`; nos três hiperparâmetros comparados, $\eta = 0,1000$, $s = 1,000$ e $N = 100$. O tempo exclusivo de treinamento final foi 0,0960 s; CV mais treinamento levou 0,349 s.

Tabela 3: Baseline: métricas em MPa, exceto R^2 , tempo total e avaliação CV.

Método	CV RMSE	Teste RMSE	Teste MAE	Teste R^2	Tempo (s)	Aval.
Baseline	5,2954	5,6039	4,1284	0,8947	0,349	1




Figura 3: Baseline: resistência observada versus prevista no holdout; a diagonal representa previsão exata.

Tabela 4: Referências suplementares no mesmo split e folds, sem busca de hiperparâmetros.

Referência adicional	CV RMSE	Teste RMSE	Teste MAE	Teste R^2	Tempo (s)
Preditor da média	16,0283	17,2964	13,9719	-0,0028	0,163
Ridge $\alpha = 1$	10,2018	11,1934	8,8976	0,5800	0,021

Essas referências foram executadas depois da comparação principal, para contextualizar a dificuldade preditiva sem interferir nos tempos dos métodos. O preditor da média ignora as features; Ridge fornece uma referência linear com regularização fixa. O baseline exigido continua sendo o GBR com defaults, e é ele que define as razões de ganho e eficiência no restante do relatório.

2.3 3. Busca em grade e espaço de hiperparâmetros

Tabela 5: Espaço fixado prospectivamente; demais hiperparâmetros permanecem nos defaults.

Hiperparâmetro	Domínio	Valores da grade
Taxa η (learning_rate)	[0,03; 0,20], log	0,03; 0,10; 0,20
Fração s (subsample)	[0,60; 1,00]	0,60; 0,80; 1,00
Árvores N (n_estimators)	[50; 200], inteiro	50; 100; 150; 200

O produto cartesiano tem $3 \times 3 \times 4 = 36$ candidatos. O `GridSearchCV` avalia todos com cinco folds e `neg_root_mean_squared_error`; os sinais são revertidos neste relatório. O menor CV RMSE foi 4,7327 MPa, em $\eta = 0,2000$, $s = 0,800$ e $N = 150$, após 4,134 s incluindo refit. Os limites são os mesmos dos métodos contínuos posteriores, mas a grade tem apenas estes pontos; isso impede tratar as resoluções de busca como idênticas.




Figura 4: RMSE CV em função de taxa de aprendizado e subsample, fixando $N = 150$ no ótimo da grade.

Ao aumentar η de 0,03 para 0,20, a mudança do RMSE no corte foi $-1,1588$ MPa para $s = 0,60$; $-1,2580$ MPa para $s = 0,80$; $-1,2171$ MPa para $s = 1,00$. A diferença entre esses efeitos evidencia dependência do efeito da taxa em relação ao subsample no corte observado. A grade esparsa permite descrever regiões melhores e piores, mas não demonstrar suavidade global ou contar ótimos locais no domínio contínuo.

2.4 4. Busca aleatória, convergência e sensibilidade

O `RandomizedSearchCV` sorteou 30 candidatos sem reposição da mesma grade, com seed 42 e os mesmos folds. A melhor configuração foi $\eta = 0,2000$, $s = 0,800$ e $N = 150$, CV RMSE $4,7327$ MPa e tempo total $3,412$ s.




Figura 5: Melhor CV RMSE acumulado na ordem registrada dos candidatos em `cv_results_`. O eixo conta avaliações, não segundos nem a ordem de término dos fits paralelos.

A busca aleatória igualou o mínimo da grade na avaliação 6. Não pode superar estritamente o mínimo CV de uma grade exaustiva quando usa um subconjunto de seus candidatos, os mesmos folds e a mesma seed do estimador. Sua possível vantagem está em alcançar qualidade semelhante com menos avaliações. Essa restrição não determina a ordenação no holdout.

Tabela 6: Associação entre valor do hiperparâmetro e RMSE CV nos 30 candidatos aleatórios.

Hiperparâmetro	ρ de Spearman	p exploratório	n
learning_rate	-0,7594	$1,14 \times 10^{-6}$	30
subsample	0,1528	0,4203	30
n_estimators	-0,6216	$2,46 \times 10^{-4}$	30

A maior associação monotônica em módulo foi de `learning_rate`, com $\rho = -0,7594$. Como o score está em RMSE positivo, sinal negativo associa valores maiores a erro

menor. Spearman é marginal: não isola interações, não estabelece causalidade e não garante importância universal. Taxa de aprendizado e número de árvores controlam conjuntamente a intensidade do boosting; subsample altera a aleatoriedade de ajuste, tornando dependência do contexto plausível.




Figura 6: Correlações de Spearman empíricas; barras em módulo não são efeitos causais.

2.5 5. Síntese do exercício 1

Tabela 7: Métodos clássicos: CV/teste em MPa, tempo CV+refit e avaliações efetivas.

Método	CV RMSE	Teste RMSE	Teste MAE	Teste R^2	Tempo (s)	Aval.
Baseline	5,2954	5,6039	4,1284	0,8947	0,349	1
Grid Search	4,7327	4,4630	3,1411	0,9332	4,134	36
Random Search	4,7327	4,4630	3,1411	0,9332	3,412	30

A otimização trouxe ganho e compensa o custo? O melhor teste entre as buscas clássicas empatou entre Grid e Random; o Random teve menor tempo, com redução de 20,36% no RMSE e custo adicional de 3,063s. A decisão econômica depende da tolerância de erro e da frequência de retreinamento, não informadas.

Quando Grid Search é preferível? Em espaços discretos pequenos, nos quais a cobertura completa é viável e uma superfície comparável precisa ser inspecionada. Em dimensões maiores, o custo cresce multiplicativamente; busca aleatória distribui um orçamento fixo de modo mais flexível[5].

O heatmap revela interação? Os efeitos extremos da taxa, acima quantificados para cada subsample, não são assumidos constantes. O corte mantém o número de árvores no ótimo; suas conclusões são locais a esse corte e aos níveis avaliados.

3 Exercício 2 — otimização Bayesiana, metaheurísticas e avaliação

3.1 6. Processo Gaussiano e Expected Improvement

O loop manual usa η em escala logarítmica e subsample, com $N = 100$ fixado antes da execução. Cinco pontos aleatórios inicializam o GP; dez aquisições posteriores totalizam 15 avaliações. O kernel é Matérn $\nu = 5/2$ com amplitude e componente de ruído ajustáveis[6]. A aquisição minimiza RMSE por Expected Improvement (EI), com $\xi = 0,01$:

$$I(x) = f_{\min} - \mu(x) - \xi, \quad \text{EI}(x) = I(x)\Phi\left(\frac{I(x)}{\sigma(x)}\right) + \sigma(x)\phi\left(\frac{I(x)}{\sigma(x)}\right).$$

O máximo de EI é aproximado numa malha 61×61 do domínio normalizado, evitando repetir pontos já observados. Isso é uma otimização discreta da aquisição no espaço contínuo, não uma garantia de máximo global analítico. A transformação de coordenadas é $\eta = 0,03(0,20/0,03)^{u_1}$ e $s = 0,60 + 0,40u_2$.

Tabela 8: Dez aquisições: posterior registrado antes da nova avaliação. RMSE e incerteza em MPa.

Iter.	Obs. prévias	$\bar{\sigma}$	EI máxima	Melhor prévio	Próx. η	Próx. s
1	5	0,1357	0,1984	4,9288	0,2000	1,0000
2	6	0,1563	0,0725	4,9288	0,0775	1,0000
3	7	0,0729	0,0265	4,9288	0,1877	0,6000
4	8	0,0473	0,0121	4,9288	0,1654	1,0000
5	9	0,0591	0,1348	4,9288	0,2000	0,8133
6	10	0,0629	0,0104	4,8608	0,2000	0,8000
7	11	0,0607	0,0027	4,8254	0,2000	0,7933
8	12	0,0936	0,0036	4,8254	0,2000	0,6000
9	13	0,0888	0,0029	4,8254	0,2000	0,6067
10	14	0,0856	0,0031	4,8254	0,2000	0,6133


A incerteza média da malha passou de 0,1357 para 0,0856 MPa, com 4 aumentos entre iterações consecutivas. Ela não precisa diminuir monotonicamente, porque os hiperparâmetros do kernel são reajustados e novas observações podem revelar estrutura inesperada. A EI máxima passou de 0,1984 para 0,0031. O critério busca equilibrar regiões promissoras e incerteza segundo o modelo; dez passos não provam convergência ao ótimo verdadeiro.

Nas três últimas aquisições, a taxa proposta esteve em $[0,2000; 0,2000]$ e o subsample em $[0,6000; 0,6133]$. Esses candidatos descrevem onde a EI concentrou a exploração final; a localização ótima real permanece desconhecida.

O melhor GP manual obteve CV RMSE 4,8254 MPa e teste 4,6763 MPa em $\eta = 0,2000$, $s = 0,800$ e $N = 100$. Comparado às 36 avaliações da grade e 30 da busca aleatória, usou 15; a diferença de qualidade está na tabela e figura seguintes. A economia de avaliações não é comparação isolada de eficiência do algoritmo: o GP explora apenas dois hiperparâmetros, enquanto os demais exploram três.

Tabela 9: Comparação do GP manual com as buscas clássicas.

Método	CV RMSE	Teste RMSE	Teste MAE	Teste R^2	Tempo (s)	Aval.
Grid Search	4,7327	4,4630	3,1411	0,9332	4,134	36
Random Search	4,7327	4,4630	3,1411	0,9332	3,412	30
GP manual	4,8254	4,6763	3,4329	0,9267	2,080	15

**Figura 7:** Convergência do GP manual e comparação com Grid/Random; o GP mantém 100 árvores.

As dez figuras individuais estão no apêndice de aquisições. Cada uma exibe posterior, observações e EI com o candidato escolhido. O corte $\mu \pm 2\sigma$ mantém o subsample do próximo candidato; as observações reais aparecem no mapa bidimensional, sem projetar pontos de outros subsamples sobre essa curva. A banda caracteriza incerteza do surrogate, não intervalo de previsão da resistência do concreto.

3.2 7. Cinco bibliotecas de otimização Bayesiana

Tabela 10: Bibliotecas aplicadas aos três hiperparâmetros do espaço completo.

Biblioteca	Configuração executada	Trials iniciados
scikit-optimize	GP Matérn 5/2; EI; 10 iniciais	40
bayes_opt	GP; UCB $\kappa = 2,576$; 5 iniciais + 35	40
Optuna	TPE; minimizar RMSE; seed 42	40
Hyperopt	TPE; <code>hp.loguniform</code> para η	40
Ray Tune	OptunaSearch + ASHA; recurso progressivo	40

Foram usados GP e aquisição explicitamente configurados no skopt[7] e no bayes_opt[8]; TPE orientou Optuna[9] e Hyperopt[10]. Cada biblioteca iniciou 40 candidatos. Os métodos contínuos compartilham os limites da grade; valores intermediários são admissíveis, e a taxa é amostrada em escala logarítmica. O inteiro N usa a mesma regra de conversão na avaliação e no ajuste final, evitando comparar um candidato com um refit diferente.

ASHA efetivo. O recurso é a fração do número de árvores proposto, com estágios 0,25; 0,50; 0,75; 1,00, warm start e RMSE nos cinco folds a cada estágio. O scheduler tem grace period 0,25 e fator de redução 2; apenas candidatos com recurso completo podem vencer[11]. Houve 24 avaliações completas e 16 podas, com 117 relatórios intermediários e 585 chamadas de fit por fold/estágio. Ao todo foram construídas 24935 árvores nos folds, descontando árvores reaproveitadas pelo warm start. Candidatos parciais não equivalem a candidatos completos; seus scores não definem o vencedor.

O tempo de busca do Ray inclui a inicialização do serviço, ao passo que o pool loky foi aquecido fora do cronômetro. A comparação de custo reflete essa convenção operacional declarada; não é um benchmark puro de tempo de treinamento nem prevê o custo de uma sessão persistente já inicializada.

Tabela 11: Cinco bibliotecas: melhor CV completo e métricas do refit no teste.

Método	CV RMSE	Teste RMSE	Teste MAE	Teste R^2	Tempo (s)	Aval.
skopt (GP + EI)	4,6436	4,5346	2,9857	0,9311	13,728	40
bayes_opt (GP + UCB)	4,6476	4,4439	3,0819	0,9338	11,133	40
Optuna (TPE)	4,6435	4,4328	3,1128	0,9341	6,906	40
Hyperopt (TPE)	4,7253	4,8299	3,4202	0,9218	5,551	40
Ray (Optuna + ASHA)	4,6096	4,6428	3,1124	0,9277	160,197	40




Figura 8: Convergência das cinco bibliotecas. Para ASHA, interpretar separadamente trabalho parcial e candidato completo.

Entre as bibliotecas, Ray (Optuna + ASHA) retornou o menor CV RMSE (4,6096 MPa), enquanto Hyperopt (TPE) teve o menor tempo total (5,551 s). O melhor CV depende da trajetória adaptativa e do orçamento de 40 trials; esta comparação não demonstra que a mesma ordenação se repetiria em outro dataset.

3.3 8. Metaheurísticas: GA, DE e PSO

8.1. Algoritmo genético. DEAP[12], população 20, 15 gerações, crossover de dois pontos com probabilidade 0,7, mutação uniforme inteira com probabilidade 0,25 e probabilidade por gene 1/3, seleção por torneio de tamanho 3. Os genes são $g_1, g_2 \in \{0, \dots, 1000\}$ e $g_3 \in \{50, \dots, 200\}$; a decodificação usa $u_1 = g_1/1000$, $u_2 = g_2/1000$, $N = g_3$. O melhor indivíduo é preservado em Hall of Fame. Fitness herdados válidos não são recalculados; a contagem corresponde às chamadas efetivamente realizadas.

O GA realizou 259 avaliações e 113 candidatos distintos. A diversidade, fração de genótipos distintos na população, passou de 100,00% para 20,00%. O maior intervalo sem melhoria acumulada durou 12 gerações, da 3 à 14; o ganho na última geração foi de apenas 0,000363 MPa. A contração da diversidade junto à estagnação sugere risco de convergência prematura, mas não prova um ótimo local nem quantifica a distância ao ótimo global desconhecido.




Figura 9: GA: fitness mínimo, médio e melhor acumulado, acompanhados da diversidade por geração.

8.2. Evolução diferencial. Foram executadas as estratégias `best1bin` e `rand1bin`, com `maxiter=15`, `popsiz=10`, mutação em $[0,5; 1,0]$ e recombinação 0,7[13]. O `popsiz` multiplica a dimensão: são 30 indivíduos, não dez. A busca usa coordenadas normalizadas, sem polish, atualização imediata e tolerância padrão 0,01. O critério de dispersão pode encerrar antes de 15 gerações.

Tabela 12: Término efetivo da evolução diferencial.

Estratégia	Gerações	Avaliações	CV	Tempo
			RMSE	(s)
DE <code>best1bin</code>	12	390	4,5612	56,677
DE <code>rand1bin</code>	12	390	4,5981	52,258




Figura 10: DE: melhor RMSE CV acumulado em best1bin e rand1bin.

Nesta execução, DE best1bin atingiu o menor CV RMSE: 4,5612 MPa. A estratégia best1bin usa o melhor vetor como base e tende a intensificar busca local; rand1bin usa uma base aleatória. A curva mostra o efeito realizado aqui; uma seed não permite transformar essa diferença em superioridade geral de uma estratégia.

O perfil observado foi: DE best1bin: 4,6235 MPa após 100 avaliações, último ganho na avaliação 310; DE rand1bin: 4,6235 MPa após 100 avaliações, último ganho na avaliação 266. O patamar final de cada curva deve ser interpretado junto à tolerância de parada, não como comprovação de convergência ao ótimo global.

8.3. Enxame de partículas. Implementação explícita das atualizações de velocidade e posição[14], com 20 partículas, 15 atualizações, $c_1 = c_2 = 1,5$ e inércias $w \in \{0,4; 0,7; 0,9\}$. A inicialização também é avaliada: $20(15 + 1) = 320$ chamadas por variante. A posição fica em $[0, 1]^3$; ao atingir uma borda, a coordenada é truncada e sua velocidade zerada. O gráfico usa média do fitness corrente do enxame, não média dos melhores pessoais.

Tabela 13: Sensibilidade do PSO à inércia, com os demais parâmetros e orçamento iguais.

Método	CV RMSE	Teste RMSE	Teste MAE	Teste R^2	Tempo (s)	Aval.
PSO $w=0,4$	4,5694	4,5138	3,1941	0,9317	55,410	320
PSO $w=0,7$	4,5339	4,6955	3,0591	0,9261	52,052	320
PSO $w=0,9$	4,5277	4,5358	3,1241	0,9310	51,257	320




Figura 11: PSO: trajetória de gbest e média do enxame corrente para as três inércias.

A menor validação entre as três inércias foi de PSO $w=0,9$, 4,5277 MPa. Inércia maior mantém mais da velocidade anterior; menor inércia reduz esse impulso. As curvas registram o compromisso observado entre exploração e estabilização, sem assumir monotonicidade do fitness médio.

A evolução do gbest nas iterações 5, 10 e 15 foi, em MPa: PSO $w=0,4$: 4,6100, 4,6090 e 4,5694; PSO $w=0,7$: 4,5849, 4,5849 e 4,5339; PSO $w=0,9$: 4,5277, 4,5277 e 4,5277. Essa comparação quantifica a velocidade e os patamares nesta seed; uma configuração de inércia não é universalmente preferível.


3.4 9. Dashboard comparativo e diagnósticos finais

Tabela 14: Comparação completa e variantes: verde marca melhores métricas e amarelo o menor tempo total; erros em MPa.

Método	CV RMSE	Teste RMSE	Teste MAE	Teste R^2	Tempo (s)	Aval.
Baseline	5,2954	5,6039	4,1284	0,8947	0,349	1
Grid Search	4,7327	4,4630	3,1411	0,9332	4,134	36
Random Search	4,7327	4,4630	3,1411	0,9332	3,412	30
GP manual	4,8254	4,6763	3,4329	0,9267	2,080	15
skopt (GP + EI)	4,6436	4,5346	2,9857	0,9311	13,728	40
bayes_opt (GP + UCB)	4,6476	4,4439	3,0819	0,9338	11,133	40
Optuna (TPE)	4,6435	4,4328	3,1128	0,9341	6,906	40
Hyperopt (TPE)	4,7253	4,8299	3,4202	0,9218	5,551	40
Ray (Optuna + ASHA)	4,6096	4,6428	3,1124	0,9277	160,197	40
GA (DEAP)	4,6010	4,5181	3,0133	0,9316	41,114	259
DE best1bin	4,5612	4,6933	3,3025	0,9262	56,677	390
DE rand1bin	4,5981	4,4135	3,0899	0,9347	52,258	390
PSO $w=0,7$	4,5339	4,6955	3,0591	0,9261	52,052	320
PSO $w=0,4$	4,5694	4,5138	3,1941	0,9317	55,410	320
PSO $w=0,9$	4,5277	4,5358	3,1241	0,9310	51,257	320

A tabela contém os 12 métodos principais e as três variantes adicionais de DE/PSO. A coluna Aval. conta candidatos registrados; em Ray inclui podas, cujo trabalho parcial é discriminado anteriormente e no apêndice. Os orçamentos diferentes são exigidos pelo

roteiro. Vantagens em qualidade com muitas avaliações não devem ser atribuídas somente ao otimizador.



Min-max entre os métodos exibidos; escala relativa, sem interpretação absoluta.

Figura 12: Radar dos 12 métodos principais: maior é melhor em todos os eixos; os limites são os do conjunto exibido.

Nos erros, o radar inverte a normalização min-max; em R^2 e $1/t$, preserva a orientação crescente. A área de um polígono depende da escala e não é uma métrica agregada validada. Para o mesmo alvo de teste, R^2 e RMSE induzem a mesma ordenação e não são eixos independentes de qualidade. Entre os 12 métodos principais exibidos, Optuna (TPE) tem o menor RMSE de teste (4,4328 MPa); Baseline tem o menor tempo total. Os demais eixos e os compromissos de qualidade são avaliados na tabela, sem impor um peso econômico arbitrário a cada dimensão.




Figura 13: Qualidade versus custo: ambas as coordenadas são minimizadas; a fronteira identifica os métodos não dominados.

A fronteira de Pareto observada contém Baseline, Random Search, GP manual, Optuna (TPE), DE rand1bin. Um método é dominado quando outro tem RMSE e tempo não maiores, com ao menos uma melhora estrita. Empates são preservados. A fronteira pode mudar com hardware, seed, orçamento ou outro conjunto de teste.

9.4. Melhor resultado descritivo no teste: DE rand1bin, em $\eta = 0,1797$, $s = 0,713$ e $N = 190$. As previsões do mesmo refit alimentam RMSE, MAE, R^2 , resíduos e importância; não houve ajuste de hiperparâmetros a partir desses diagnósticos.




Figura 14: Vencedor descritivo no holdout: observado versus previsto e distribuição dos resíduos $y - \hat{y}$.

Em 201 resíduos, a média foi 0,7045 MPa e o desvio padrão amostral 4,3678 MPa. Shapiro–Wilk: $W = 0,9303$, $p = 3,36 \times 10^{-8}$. Rejeita-se a hipótese de normalidade ao nível

exploratório de 5%. O diagnóstico se refere aos resíduos, não à distribuição marginal do alvo; não normalidade não invalida automaticamente o GBR ou as métricas de erro.




Figura 15: Importância das features do GBR final por redução acumulada de impureza.

Os três maiores valores foram Idade (35,32%); Cimento (28,12%); Água (10,05%). Essa importância descreve o modelo ajustado, pode se distribuir entre variáveis correlacionadas e não mede efeito causal de um ingrediente sobre a resistência.

3.5 10. Importância, robustez, custo-benefício e recomendação

10.1. Importância dos hiperparâmetros. Foi utilizado `get_param_importances` do Optuna com avaliador fANOVA e seed 42[9]. O HPO principal usa todas as 804 linhas de treino; outra busca de 40 trials usa uma subamostra aleatória de 402 linhas, preservando o holdout. Não se inclui o teste no que se chama treino integral. Os folds da subamostra seguem a mesma regra, mas suas observações diferem; a comparação é uma sensibilidade ao tamanho do treino.

Tabela 15: Importâncias normalizadas fANOVA após 40 trials Optuna em cada tamanho.

Hiperparâmetro	Treino integral	Metade do treino
learning_rate	68,36%	30,21%
n_estimators	29,91%	62,58%
subsample	1,73%	7,21%




Figura 16: Comparação da importância dos hiperparâmetros com treino integral e subamostra de 50%.

O principal hiperparâmetro no treino integral foi `learning_rate` e na subamostra foi `n_estimators`. O RMSE de teste do Optuna passou de 5,6774 MPa na subamostra para 4,4328 MPa no treino integral. Essas importâncias dependem do espaço, dos trials observados e do avaliador; não são uma propriedade fixa do dataset nem são diretamente equivalentes às correlações marginais de Spearman.

10.2. Robustez do procedimento. Os vencedores por CV e por teste foram submetidos ao procedimento completo de busca nas seeds $\{0, 7, 21, 42, 99\}$, mantendo dados, holdout e folds. Variaram as seeds do otimizador e do GBR. A execução principal de seed 42 foi reutilizada. Se os vencedores coincidem, há apenas uma série de cinco repetições, sem duplicação de custo.

Tabela 16: Reexecuções completas do HPO com dados e partições fixos.

Método	Seed	CV RMSE	Teste RMSE	Tempo (s)
DE rand1bin	0	4,6413	4,5569	40,783
DE rand1bin	7	4,6532	4,6909	33,620
DE rand1bin	21	4,6508	4,5783	33,120
DE rand1bin	42	4,5981	4,4135	52,258
DE rand1bin	99	4,6524	4,4555	31,526
PSO w=0,9	0	4,5548	4,6603	43,779
PSO w=0,9	7	4,5661	4,5388	48,289
PSO w=0,9	21	4,5955	4,4263	49,861
PSO w=0,9	42	4,5277	4,5358	51,257
PSO w=0,9	99	4,5643	4,4826	50,981




Figura 17: RMSE de teste do vencedor descritivo nas cinco seeds; não é intervalo de confiança de generalização.

DE rand1bin: RMSE de teste médio $4,5390 \pm 0,1092$ MPa (desvio padrão amostral, $n = 5$), intervalo observado $[4,4135; 4,6909]$ MPa. A variação relativa DP/média foi 2,41%. São cinco aleatoriedades de um mesmo dataset; a dispersão não quantifica incerteza entre populações, lotes ou outros conjuntos de teste.

PSO w=0,9: RMSE de teste médio $4,5288 \pm 0,0867$ MPa (desvio padrão amostral, $n = 5$), intervalo observado $[4,4263; 4,6603]$ MPa. A variação relativa DP/média foi 1,92%. São cinco aleatoriedades de um mesmo dataset; a dispersão não quantifica incerteza entre populações, lotes ou outros conjuntos de teste.

A maior dispersão relativa foi 2,41% do RMSE médio. Isso indica estabilidade relativa às cinco seeds estudadas no holdout fixo, com a faixa de variação acima explicitada; não assegura estabilidade em produção nem sustenta interpretar diferenças de centésimos de MPa como decisivas.

10.3. Custo-benefício computacional. Para erro menor ser melhor, a razão exigida é

$$E_m = \frac{(\text{RMSE}_0 - \text{RMSE}_m)/\text{RMSE}_0}{t_m - t_0}.$$

Ela usa segundos adicionais de busca/CV+refit. O baseline é indefinido; denominadores não positivos também não recebem uma divisão artificial por epsilon.

Tabela 17: Eficiência relativa ao baseline; traço significa razão não definida.

Método	Ganho relativo	Δt (s)	E_m (s ⁻¹)
Baseline	0,00%	0,000	—
Grid Search	20,36%	3,785	0,0537830
Random Search	20,36%	3,063	0,0664614
GP manual	16,55%	1,731	0,0956433
skopt (GP + EI)	19,08%	13,379	0,0142618
bayes_opt (GP + UCB)	20,70%	10,784	0,0191949
Optuna (TPE)	20,90%	6,557	0,0318695
Hyperopt (TPE)	13,81%	5,202	0,0265499
Ray (Optuna + ASHA)	17,15%	159,848	0,0010729
GA (DEAP)	19,38%	40,765	0,0047530
DE best1bin	16,25%	56,328	0,0028846
DE rand1bin	21,24%	51,908	0,0040921
PSO w=0,7	16,21%	51,702	0,0031353
PSO w=0,4	19,45%	55,060	0,0035327
PSO w=0,9	19,06%	50,908	0,0037437

A maior razão definida foi a de GP manual, $E = 0,0956433 \text{ s}^{-1}$. Essa razão responde ao ganho marginal por tempo adicional nesta máquina; pode favorecer ganhos pequenos e baratos, e não inclui inferência, manutenção ou valor econômico do erro.

10.4. Recomendação justificada (até dez linhas).

Adotaria Optuna TPE como opção operacional: CV de 4,6435 MPa, teste de 4,4328 MPa e 6,906 s em 40 avaliações. A API padronizada facilita integração ao pipeline e reprodução com seeds, versões e logs. Este é um julgamento pós-resultados de custo e qualidade: a seleção por CV permanece PSO w=0,9, e o vencedor descritivo do teste é DE rand1bin. Antes de produção, validaria em novos lotes e confrontaria o erro com a tolerância de engenharia.

A Parâmetros selecionados e contabilidade computacional

Tabela 18: Melhores parâmetros por CV; baseline registra seus defaults.

Método	learning_rate	subsample	n_estimators
Baseline	0,100000	1,000000	100
Grid Search	0,200000	0,800000	150
Random Search	0,200000	0,800000	150
GP manual	0,200000	0,800000	100
skopt (GP + EI)	0,199032	0,716111	198
bayes_opt (GP + UCB)	0,150675	0,843548	197
Optuna (TPE)	0,184487	0,697361	171
Hyperopt (TPE)	0,153621	0,720169	141
Ray (Optuna + ASHA)	0,190575	0,701679	188
GA (DEAP)	0,192554	0,712400	199
DE best1bin	0,185928	0,922905	166
DE rand1bin	0,179739	0,713162	190
PSO w=0,7	0,200000	0,681240	198
PSO w=0,4	0,193127	0,909809	185
PSO w=0,9	0,168098	0,622404	200

Tabela 19: Tempos registrados na comparação principal: busca/validação, refit e soma das duas etapas.

Método	Busca/CV (s)	Refit (s)	Total (s)
Baseline	0,253	0,0960	0,349
Grid Search	3,991	0,1430	4,134
Random Search	3,288	0,1239	3,412
GP manual	1,990	0,0898	2,080
skopt (GP + EI)	13,558	0,1699	13,728
bayes_opt (GP + UCB)	10,947	0,1866	11,133
Optuna (TPE)	6,759	0,1468	6,906
Hyperopt (TPE)	5,429	0,1218	5,551
Ray (Optuna + ASHA)	160,008	0,1887	160,197
GA (DEAP)	40,953	0,1614	41,114
DE best1bin	56,532	0,1455	56,677
DE rand1bin	52,105	0,1530	52,258
PSO w=0,7	51,899	0,1527	52,052
PSO w=0,4	55,241	0,1690	55,410
PSO w=0,9	51,112	0,1453	51,257

Tabela 20: Contagem de avaliações e ajustes. No Ray, fit CV é uma chamada por fold/estágio, com warm start; não equivale a treinamento completo do zero.

Método	Aval.	Únicos	Fits CV	Trials completos	Trials podados
Baseline	1	1	5	1	0
Grid Search	36	36	180	36	0
Random Search	30	30	150	30	0
GP manual	15	15	75	15	0
skopt (GP + EI)	40	40	200	40	0
bayes_opt (GP + UCB)	40	40	200	40	0
Optuna (TPE)	40	40	200	40	0
Hyperopt (TPE)	40	40	200	40	0
Ray (Optuna + ASHA)	40	40	585	24	16
GA (DEAP)	259	113	1295	259	0
DE best1bin	390	389	1950	390	0
DE rand1bin	390	390	1950	390	0
PSO w=0,7	320	311	1600	320	0
PSO w=0,4	320	319	1600	320	0
PSO w=0,9	320	319	1600	320	0

O baseline usa perda quadrática, profundidade máxima 3 e demais parâmetros padrão da versão registrada. Fora das três dimensões acima, os métodos preservam esses parâmetros. Contagens distintas de candidatos e candidatos únicos mostram revisitas; não foi aplicado cache de scores entre otimizadores para artificialmente reduzir seu custo. O custo das sensibilidades é adicional à tabela principal.

B Ambiente e evidências de reprodução

Fontes do relatório. O arquivo `Exercício_Aula5.tex` e a pasta `Figuras_Aula5` acompanham os dados e o notebook executado. As tabelas são geradas a partir dos resultados registrados; alterações de diagramação não reexecutam as buscas nem modificam as métricas arquivadas.

Python: 3.12.1 (tags/v3.12.1:2305ca5, Dec 7 2023, 22:03:25) [MSC v.1937 64 bit (AMD64)]. Plataforma: Windows-11-10.0.26200-SP0. Processador: identificador não disponibilizado pelo sistema. CPUs lógicas detectadas: 16.

Tabela 21: Versões registradas na execução, distintas das versões futuras de documentação online.

Biblioteca	Versão	Biblioteca	Versão
numpy	2.5.3	bayesian-optimization	3.3.0
pandas	3.0.6	optuna	5.0.0
scipy	1.18.1	hyperopt	0.3.0
scikit-learn	1.9.1	ray	2.58.0
joblib	1.6.0	deap	1.4.4
threadpoolctl	3.7.0	matplotlib	3.11.2
ucimlrepo	0.0.7	seaborn	0.13.2
scikit-optimize	0.10.2		

São fornecidos notebook executado, código de experimentos, dados e contrato, manifesto de split/folds, resultados por trial, previsões, figuras e fontes do relatório. Os arquivos `result.json`, `trials.csv`, `predictions.csv` e `analysis.json` conectam números e figuras à mesma execução. Reexecutar o HPO pode alterar tempos; seeds controlam aleatoriedade, mas não garantem igualdade bit a bit entre bibliotecas, versões e plataformas.

Os registros por método guardam o SHA-256 integral do script executado. Foram encontrados 2 hashes de código na comparação principal. Um hash identifica o arquivo inteiro; uma diferença não implica automaticamente mudança no algoritmo, mas deve ser confrontada ao histórico de alterações.

Baseline, Grid Search, Random Search, GP manual, skopt (GP + EI), bayes_opt (GP + UCB), Optuna (TPE), Hyperopt (TPE):

`f652fe5eab5e5ceec8ea6b8c53e7de4b31fc3f14f453fd695768e8e0b0cf3aea8`

Ray (Optuna + ASHA), GA (DEAP), DE best1bin, DE rand1bin, PSO w=0,7, PSO w=0,4, PSO w=0,9:

`4bd4e786823cd9b0637186f1a46f4651d3e092b341d8316d3cdfc3c7c1dceda1`

uci165_raw.csv, SHA-256:

`becab3d4456f67058a4db247ef0ae2dfbe6cef8e50c18898beed13e100202c5d`

clean.csv, SHA-256:

`503672bc1db72cdcb457df56bc34d44e94a933cee18b7a8baaabc8540ac7719e`

split-manifest.csv, SHA-256:

`53a672d829c8bea46dc35372870640922b377684b0b6bd2985b8fe7a2877e0c5`

prepared.npz, SHA-256:


`a642bb83837a56a7772fdbf5f876265a3be1524b76a43d90db3ad9d4972c7b14`

A integridade estrutural foi conferida por índices de treino/teste disjuntos, contagem de candidatos e recálculo de métricas a partir das previsões. Isso não substitui validação científica independente. O compromisso metodológico mais relevante é manter as limitações visíveis: um único dataset, budgets diferentes, busca contínua versus grade discreta e seleção descritiva pelo teste.

C Dez iterações do GP manual

Aquisição 1

GP manual — aquisição 1/10; 5 observações anteriores




Observações no mapa 2D; somente as do mesmo subsample entram no corte. $n_estimators = 100$.

Figura 18: Posterior e EI antes da aquisição 1, com 5 observações. Candidato: $\eta = 0,2000$, $s = 1,0000$. As observações reais são exibidas no mapa 2D; o corte mantém o subsample fixo e não projeta pontos de outras seções.

Aquisição 2

GP manual — aquisição 2/10; 6 observações anteriores




Observações no mapa 2D; somente as do mesmo subsample entram no corte. $n_{\text{estimators}} = 100$.

Figura 19: Posterior e EI antes da aquisição 2, com 6 observações. Candidato: $\eta = 0,0775$, $s = 1,0000$. As observações reais são exibidas no mapa 2D; o corte mantém o subsample fixo e não projeta pontos de outras seções.

Aquisição 3

GP manual — aquisição 3/10; 7 observações anteriores




Observações no mapa 2D; somente as do mesmo subsample entram no corte. $n_estimators = 100$.

Figura 20: Posterior e EI antes da aquisição 3, com 7 observações. Candidato: $\eta = 0,1877$, $s = 0,6000$. As observações reais são exibidas no mapa 2D; o corte mantém o subsample fixo e não projeta pontos de outras seções.

Aquisição 4

GP manual — aquisição 4/10; 8 observações anteriores




Observações no mapa 2D; somente as do mesmo subsample entram no corte. $n_{\text{estimators}} = 100$.

Figura 21: Posterior e EI antes da aquisição 4, com 8 observações. Candidato: $\eta = 0,1654$, $s = 1,0000$. As observações reais são exibidas no mapa 2D; o corte mantém o subsample fixo e não projeta pontos de outras seções.

Aquisição 5

GP manual — aquisição 5/10; 9 observações anteriores




Observações no mapa 2D; somente as do mesmo subsample entram no corte. $n_estimators = 100$.

Figura 22: Posterior e EI antes da aquisição 5, com 9 observações. Candidato: $\eta = 0,2000$, $s = 0,8133$. As observações reais são exibidas no mapa 2D; o corte mantém o subsample fixo e não projeta pontos de outras seções.

Aquisição 6

GP manual — aquisição 6/10; 10 observações anteriores




Observações no mapa 2D; somente as do mesmo subsample entram no corte. $n_estimators = 100$.

Figura 23: Posterior e EI antes da aquisição 6, com 10 observações. Candidato: $\eta = 0,2000$, $s = 0,8000$. As observações reais são exibidas no mapa 2D; o corte mantém o subsample fixo e não projeta pontos de outras seções.

Aquisição 7

GP manual — aquisição 7/10; 11 observações anteriores




Observações no mapa 2D; somente as do mesmo subsample entram no corte. $n_estimators = 100$.

Figura 24: Posterior e EI antes da aquisição 7, com 11 observações. Candidato: $\eta = 0,2000$, $s = 0,7933$. As observações reais são exibidas no mapa 2D; o corte mantém o subsample fixo e não projeta pontos de outras seções.

Aquisição 8

GP manual — aquisição 8/10; 12 observações anteriores




Observações no mapa 2D; somente as do mesmo subsample entram no corte. $n_{\text{estimators}} = 100$.

Figura 25: Posterior e EI antes da aquisição 8, com 12 observações. Candidato: $\eta = 0,2000$, $s = 0,6000$. As observações reais são exibidas no mapa 2D; o corte mantém o subsample fixo e não projeta pontos de outras seções.

Aquisição 9

GP manual — aquisição 9/10; 13 observações anteriores




Observações no mapa 2D; somente as do mesmo subsample entram no corte. $n_{\text{estimators}} = 100$.

Figura 26: Posterior e EI antes da aquisição 9, com 13 observações. Candidato: $\eta = 0,2000$, $s = 0,6067$. As observações reais são exibidas no mapa 2D; o corte mantém o subsample fixo e não projeta pontos de outras seções.

Aquisição 10

GP manual — aquisição 10/10; 14 observações anteriores



Observações no mapa 2D; somente as do mesmo subsample entram no corte. $n_{\text{estimators}} = 100$.

Figura 27: Posterior e EI antes da aquisição 10, com 14 observações. Candidato: $\eta = 0,2000$, $s = 0,6133$. As observações reais são exibidas no mapa 2D; o corte mantém o subsample fixo e não projeta pontos de outras seções.

Referências

- [1] Yeh, I. (1998). *Concrete Compressive Strength* [Dataset]. UCI Machine Learning Repository. DOI: [10.24432/C5PK67](https://doi.org/10.24432/C5PK67).
- [2] juniortlr. *rnd-superpowers*, versão fixada no commit f68892c8b7adba358b8aa437eec00a89fe88d340. <https://github.com/juniortlr/rnd-superpowers/commit/f68892c8b7adba358b8aa437eec00a89fe88d340>.
- [3] Coelho, L. dos S. (2026). *Aula 05: Otimização de hiperparâmetros*. EELT7025, PPGE, Universidade Federal do Paraná. Notebook fornecido na disciplina.
- [4] Scikit-learn. *GradientBoostingRegressor; Pipeline; GridSearchCV; RandomizedSearchCV*. Documentação oficial. <https://scikit-learn.org/stable/modules/generated/sklearn.ensemble.GradientBoostingRegressor.html>.
- [5] Bergstra, J.; Bengio, Y. (2012). Random search for hyper-parameter optimization. *Journal of Machine Learning Research*, 13, 281–305. <https://jmlr.org/papers/v13/bergstra12a.html>.
- [6] Rasmussen, C. E.; Williams, C. K. I. (2006). *Gaussian Processes for Machine Learning*. MIT Press. <https://gaussianprocess.org/gpml/>.

- [7] Scikit-optimize. *BayesSearchCV*. Documentação oficial. <https://scikit-optimize.readthedocs.io/en/stable/modules/generated/skopt.BayesSearchCV.html>.
- [8] Bayesian-optimization. *BayesianOptimization*. <https://github.com/bayesian-optimization/BayesianOptimization>.
- [9] Akiba, T. et al. (2019). Optuna: a next-generation hyperparameter optimization framework. *KDD*, 2623–2631. DOI:10.1145/3292500.3330701. Documentação de importância: https://optuna.readthedocs.io/en/stable/reference/generated/optuna.importance.get_param_importances.html.
- [10] Bergstra, J.; Bardenet, R.; Bengio, Y.; Kégl, B. (2011). Algorithms for hyperparameter optimization. *Advances in Neural Information Processing Systems*, 24.
- [11] Ray Tune. *OptunaSearch e ASHAScheduler*. Documentação oficial. <https://docs.ray.io/en/latest/tune/api/doc/ray.tune.schedulers.ASHAScheduler.html>.
- [12] DEAP. *Evolutionary algorithms made easy*. Documentação oficial. <https://deap.readthedocs.io/en/master/>.
- [13] Storn, R.; Price, K. (1997). Differential evolution: a simple and efficient heuristic for global optimization over continuous spaces. *Journal of Global Optimization*, 11, 341–359. DOI:10.1023/A:1008202821328.
- [14] Kennedy, J.; Eberhart, R. (1995). Particle swarm optimization. *ICNN'95*, 4, 1942–1948. DOI:10.1109/ICNN.1995.488968.